

Projet Data Science

Objectif

Réaliser une chaîne complète de traitement et d'analyse de données massives, depuis la collecte jusqu'à la mise à disposition d'un modèle prédictif via une interface de démonstration.

Travail demandé

1. Choix du problème

Choisir une problématique métier pertinente (fraude, recommandation, santé, énergie, transport, réseaux sociaux, etc.) et la présenter brièvement.

2. Recherche d'un dataset Big Data

Sélectionner un dataset de grande taille (plusieurs millions d'enregistrements ou plusieurs Go de données).

Présenter :

- la source ;
- le volume ;
- la structure des données ;
- les défis liés à son exploitation.

3. Stockage des données

Choisir entre **SQL** et **NoSQL**.

Vous devrez :

- justifier votre choix en fonction des caractéristiques des données ;

- implémenter la solution retenue ;
- optimiser les performances (indexation, partitionnement, etc.)

4. Pipeline ETL

Mettre en place un processus ETL complet :

- Extraction des données ;
- Transformation (nettoyage, traitement des valeurs manquantes, encodage, normalisation, etc.) ;
- Chargement dans la base de données.

L'automatisation du pipeline est fortement encouragée.

5. Analyse des données

Réaliser une analyse exploratoire (EDA) :

- statistiques descriptives ;
- visualisations ;
- corrélations ;
- détection d'anomalies ;
- interprétation des résultats.

6. Machine Learning

Implémenter et comparer plusieurs approches :

- Apprentissage supervisé ;
- Apprentissage non supervisé etc ...

Méthodes non vues en cours (optionnel)

Choisir au moins une méthode avancée, l'étudier et l'intégrer au projet.

7. Évaluation des modèles

Comparer les modèles à l'aide de métriques adaptées et justifier le choix du modèle final.

8. Interface de démonstration

Développer une interface simple (Streamlit, Gradio, Dash, etc.) permettant :

- de visualiser les données ;
- d'utiliser le modèle entraîné ;
- d'afficher les résultats et prédictions.

Critère principal d'évaluation

Une attention particulière sera portée à :

- la pertinence de l'architecture choisie ;
- la justification SQL/NoSQL ;
- la qualité du pipeline ETL ;
- les performances des modèles (à arbitrer en fonction de la complexité du problème);
- **la rapidité de traitement et les temps de réponse** (chargement, requêtes, entraînement et inférence).

Livrables

- Rapport technique (README)
- Dépôt Git contenant l'ensemble du code
- Présentation et démonstration finale (15 minutes)